



**Universidad
de Valladolid**

UNIVERSIDAD DE VALLADOLID

FACULTAD DE CIENCIAS

Mejora de la Ordenación Circular y Robustez en Transcriptómica Circadiana mediante Métodos basados en CPCA

Trabajo de Fin de Grado en Estadística

Autor:

Samuel Ortega Bustos

Tutores:

Yolanda Larriba González

Juan Camilo Yepes Borrero

Curso Académico 2025-2026

3 de junio de 2026

Resumen

La estimación de la fase circadiana a partir de datos transcriptómicos representa un reto central en cronobiología, especialmente en estudios humanos donde las etiquetas temporales suelen ser inaccesibles por restricciones éticas o clínicas. El algoritmo CIRCUST, basado en el Análisis de Componentes Principales Circulares (CPCA), ha demostrado ser una herramienta prometedora para la reconstrucción del orden temporal. Sin embargo, su implementación actual carece de la modularidad necesaria y de mecanismos para ajustar covariables o manejar muestreos dispersos.

Este trabajo presenta una re-implementación modular y eficiente de CIRCUST en Python, junto con un refinamiento metodológico profundo. Las mejoras incluyen la integración de ajustes por covariables y una optimización de la ordenación circular para mejorar la inferencia de fase. Además, se ha desarrollado un marco de simulación para evaluar sistemáticamente la robustez del modelo frente a perturbaciones como el ruido y los efectos por lotes. Finalmente, el pipeline mejorado se valida utilizando conjuntos de datos transcriptómicos reales del cerebro humano post-mortem, demostrando una mayor precisión y relevancia biológica.

Palabras clave: Cronobiología, Transcriptómica, Ordenación Circular, CPCA, Python.

Abstract

Estimating circadian phase from transcriptomic data is a central challenge in chronobiology, particularly in human studies where time-of-day labels are often unavailable. The CIRCUST algorithm, based on Circular Principal Component Analysis (CPCA), offers a promising approach for temporal order reconstruction. However, its current implementation lacks modularity, extensibility, and built-in mechanisms to adjust for covariates or to handle sparse sampling patterns.

This project presents a modular and efficient re-implementation of CIRCUST in Python, alongside a deep methodological refinement. Improvements include the integration of covariate adjustments and enhanced circular ordering for better phase inference. Furthermore, a simulation framework is developed to systematically evaluate robustness against perturbations such as noise and batch effects. Finally, the improved pipeline is validated using real post-mortem human brain transcriptomic datasets, demonstrating improved accuracy and biological relevance.

Keywords: Chronobiology, Transcriptomics, Circular Ordering, CPCA, Python.

Índice general

Índice de figuras	III
Índice de tablas	IV
1. Introducción	1
1.1. Sistema circadiano: función, organización y relevancia	1
1.2. Estimación del orden temporal	3
1.3. Métodos actuales de estimación del orden temporal	4
1.3.1. Limitaciones de los métodos actuales	5
1.4. Objetivos del trabajo	5
1.5. Asignaturas relacionadas con el Trabajo de Fin de Grado	6
2. Metodología	8
2.1. El algoritmo CIRCUST	8
2.1.1. Visión general del flujo de trabajo	9
2.1.2. Ordenación circular mediante CPCA	10
2.1.3. Sincronización con el tiempo biológico	11
2.1.4. Modelado de la ritmicidad: del Cosinor al modelo FMM	11
2.1.5. Selección de genes rítmicos y orden robusto	12
2.1.6. Aportaciones de CIRCUST frente a los métodos previos	12
2.2. Otros métodos de estimación del orden temporal	14
2.2.1. Métodos basados en <i>autoencoders</i> : CYCLOPS y PENN	14
2.2.2. Métodos para datos multi-tejido: CHIRAL	16
2.3. Fundamentos matemáticos de CPCA y FMM	17
2.3.1. Preliminares de estadística circular	17
2.3.2. Ordenación circular mediante CPCA	18
2.3.3. El modelo FMM	18
2.3.4. Inferencia con restricciones de orden (ORI)	19
2.4. Mejora de CIRCUST: implementación modular y eficiencia	19
2.4.1. Estructura modular	20
2.4.2. Eficiencia en Python	20

2.5. Modelo FMM robusto	21
2.6. El problema de sincronización de órdenes circulares	23
2.6.1. Formulación del problema y los $2n$ órdenes	23
2.6.2. Algoritmo de minimización para la sincronización	23
2.7. Ordenación agregada: orden de consenso	24
2.8. Marco de validación y métricas de similitud	24
3. Resultados y Simulaciones	25
4. Conclusiones y Trabajo Futuro	26
Bibliografía	27

Índice de figuras

1.1. Patrón rítmico de un gen circadiano en 24 horas.	1
1.2. Organización jerárquica del sistema circadiano.	2
2.1. Flujo de trabajo del algoritmo CIRCUST.	9
2.2. Arquitectura del <i>autoencoder</i> circular de CYCLOPS.	15

Índice de tablas

Capítulo 1

Introducción

1.1. Sistema circadiano: función, organización y relevancia

Los ritmos circadianos (del latín *circa diem*, “alrededor de un día”) son oscilaciones biológicas endógenas con un periodo aproximado de 24 horas. Están presentes en la práctica totalidad de los organismos, desde cianobacterias hasta seres humanos, y regulan procesos fisiológicos, metabólicos y conductuales. La Figura 1.1 ilustra la forma típica de uno de estos ritmos a lo largo del día.




Figura 1.1: Patrón rítmico de un gen circadiano a lo largo de 24 horas. El pico marca la máxima expresión y define la fase del ritmo.

A nivel molecular, el reloj circadiano es un mecanismo genético bien caracterizado. Su funcionamiento se basa en un bucle de retroalimentación: un grupo de genes activa la producción de unas proteínas que, al acumularse, bloquean a los genes que las habían activado; cuando esas proteínas se degradan, el bloqueo desaparece y el ciclo vuelve a empezar. Este mecanismo se conoce como bucle de retroalimentación transcripcional-traducciona (TTFL, por sus siglas en inglés), y los genes que lo forman constituyen el denominado *core clock*. En los mamíferos, los reguladores positivos (los factores de transcripción CLOCK y BMAL1) activan la expresión de los reguladores negativos (las

familias de proteínas Period, PER, y Cryptochrome, CRY), que a su vez inhiben a los primeros [1]. Completar este ciclo de activación e inhibición tarda aproximadamente 24 horas, lo que fija el ritmo basal de la célula.

El sistema está organizado de forma jerárquica (Figura 1.2). Un reloj central, situado en el núcleo supraquiasmático del hipotálamo [2], recibe información lumínica desde la retina y la utiliza para sincronizarse con el ciclo externo de luz y oscuridad. Este reloj central coordina, mediante señales nerviosas y hormonales, los relojes periféricos presentes en la mayoría de órganos y tejidos (corazón, hígado, pulmones o tejido adiposo), de modo que sus ritmos se mantienen alineados entre sí y con el entorno.




Figura 1.2: Organización jerárquica del sistema circadiano: el reloj central (NSQ) se sincroniza con la luz a través de la retina y coordina los relojes periféricos.

Como consecuencia de esta regulación, numerosos procesos biológicos quedan bajo control circadiano y muestran patrones oscilatorios a lo largo de las 24 horas del día. Es el caso de la temperatura corporal, la presión arterial o los niveles de hormonas como el cortisol y la melatonina, cuyos valores varían de forma predecible según la hora [3, 4].

A nivel transcriptómico, las tecnologías de secuenciación de alto rendimiento han mostrado que una proporción elevada del genoma (hasta un 40–50 % según el tejido) está bajo control circadiano [5, 6], de modo que la actividad de las células cambia de forma sustancial con la hora del día.

Por este motivo, identificar los genes circadianos tiene un interés directo: son los responsables de coordinar funciones biológicas y de garantizar la sincronización de los procesos del organismo. Además, el instante de máxima expresión de cada gen, *su pico*, señala el momento del día en que se desencadena la función biológica asociada, por lo que conocer esos tiempos permite interpretar cuándo y cómo se activa cada proceso.

La relevancia clínica de estos ritmos es doble. Por un lado, la desalineación crónica del reloj circadiano, asociada al trabajo por turnos (*shift work*), al *jet lag* social o a la exposición nocturna a luz artificial, constituye un factor de riesgo para trastornos metabólicos (diabetes tipo 2, obesidad), enfermedades cardiovasculares, trastornos neurodegenerativos y diversos tipos de cáncer [7, 8]. Por otro, dado que miles de genes fluctúan a lo largo del día, la disponibilidad de muchas dianas terapéuticas depende de la hora: la eficacia y la toxicidad de numerosos fármacos varían según el momento de administración, lo que constituye el objeto de la cronofarmacología [9, 10].

1.2. Estimación del orden temporal

Para identificar genes rítmicos y caracterizar sus picos es necesario conocer el instante del ciclo en que se obtuvo cada muestra. Cuando esa etiqueta temporal no está disponible, el problema se reformula como la **estimación del orden temporal** de las muestras, ordenarlas según su posición latente dentro del ciclo de 24 horas a partir únicamente de los datos de expresión. Como el ciclo es periódico (la hora 0 coincide con la 24), ese orden no es lineal sino **circular**; las muestras se disponen sobre una circunferencia y lo que se estima es su orden circular, es decir, su posición angular relativa, y no un tiempo absoluto. Recuperar después el origen y el sentido de giro, situar el orden estimado sobre el tiempo biológico real, constituye el problema de sincronización, que requiere información adicional, como genes de fase conocida que actúen de ancla. Un ejemplo característico es *ARNTL* (también conocido como *BMAL1*), cuya fase de expresión está bien caracterizada y se sitúa en antifase respecto a la de los genes *PER* y *CRY* [11].

Los datos de partida se organizan en una matriz de expresión génica en la que las filas corresponden a los genes (del orden de decenas de miles) y las columnas a las muestras, es decir, a los distintos tiempos. Una característica esencial de estos datos es que solo una pequeña fracción de los genes presenta un patrón rítmico claro, la mayoría son poco o nada rítmicos y se comportan como ruido de fondo, lo que dificulta extraer la señal circular.

La disponibilidad de etiquetas temporales depende del tipo de estudio. En modelos animales, como el ratón, las muestras se obtienen a tiempos controlados y conocidos, pero a costa de un número reducido de individuos y de tejidos concretos [12]. En humanos, en cambio, los estudios a gran escala recurren a tejido post-mortem, donde la hora de la muerte suele ser desconocida o imprecisa y cada donante aporta una única muestra por tejido. El consorcio **GTE_x** (*Genotype-Tissue Expression*) [13] constituye la referencia mundial de este tipo de datos, al proporcionar un atlas masivo de expresión génica en múltiples tejidos humanos; es también el escenario en el que se enmarca la metodología empleada en el trabajo de Circust [14].

El estudio del orden temporal en humanos presenta varios desafíos específicos:

1. **Imposibilidad de muestreos seriados.** A diferencia de los modelos animales, obtener biopsias repetidas de tejidos internos a lo largo del día es inviable en humanos. Ello obliga a recurrir a tejidos accesibles, como sangre o piel, o a muestras post-mortem, y limita la extrapolación de los resultados a órganos con una ritmicidad presumiblemente distinta [15].
2. **Variabilidad biológica y ambiental.** Factores como el trabajo nocturno, la exposición a luz artificial, los horarios irregulares de comida o el estrés desincronizan el ritmo interno de cada individuo. Las diferencias genéticas entre sujetos modifican

además la fase y la amplitud de sus ritmos. El resultado es una elevada variabilidad entre muestras que dificulta identificar patrones consistentes [16].

3. **Incertidumbre en muestras post-mortem.** Además de desconocerse la fase circadiana en el momento del fallecimiento, tras la muerte el ARN se degrada de forma progresiva. Esta degradación altera los niveles de expresión detectados e introduce ruido y sesgos que dificultan distinguir la señal rítmica real [17].
4. **Patrones de expresión no sinusoidales.** La expresión de muchos genes circadianos no sigue una onda simétrica, sino formas asimétricas y complejas, lo que complica su modelización, especialmente con datos ruidosos o incompletos [18].

Estos desafíos explican por qué, en la práctica, el escenario habitual en humanos consiste en disponer de expresión post-mortem de varios tejidos de un mismo donante sin una etiqueta temporal fiable. Es precisamente esta situación la que motiva el desarrollo de métodos capaces de estimar el orden temporal a partir de los propios datos de expresión.

1.3. Métodos actuales de estimación del orden temporal

Se han propuesto distintos métodos para estimar el orden temporal a partir exclusivamente de los datos de expresión. Pueden agruparse en enfoques basados en estadística multivariante y enfoques basados en aprendizaje automático. A continuación se enumeran los más relevantes; el método empleado en este trabajo se desarrolla en detalle en el Capítulo 2.

- **CIRCUST** [14]: proyecta los genes reloj sobre el círculo unidad mediante Análisis de Componentes Principales Circulares (CPCA) [19] y ajusta las curvas de expresión con los modelos ORI [20] y FMM [18], obteniendo un orden temporal interpretable.
- **CYCLOPS** [21] y su evolución **CYCLOPS 2.0** [22]: emplean un autoencoder con un cuello de botella circular para asignar una fase a cada muestra; la versión 2.0 incorpora corrección de covariables.
- **PENN** [23]: red neuronal que, además de minimizar el error de reconstrucción, impone que la expresión siga una curva periódica al ordenar las muestras por la fase estimada.
- **CHIRAL** [24]: método orientado a datos multi-tejido que estima primero una fase por tejido y la integra después en una fase global por donante.

1.3.1. Limitaciones de los métodos actuales

Ninguno de los métodos disponibles resuelve por completo el problema, y todos presentan compromisos que conviene comparar de forma conjunta. Los enfoques basados en redes neuronales (CYCLOPS y PENN) modelan bien relaciones no lineales, pero funcionan como cajas negras: carecen de una trazabilidad estadística estricta y son propensos al sobreajuste cuando el número de muestras es reducido, una situación habitual en transcriptómica. CHIRAL, por su parte, fue diseñado para infraestructuras multi-tejido masivas y pierde eficacia en estudios de un solo tejido o en cohortes pequeñas, al depender de la jerarquía entre los órganos de un mismo donante para estabilizar la inferencia.

CIRCUST ofrece la ventaja de una base estadística transparente (CPCA y modelo FMM), pero su formulación e implementación actuales presentan tres limitaciones. En primer lugar, es vulnerable a los factores de confusión: asume que toda la varianza cíclica capturada por los primeros componentes principales procede del reloj biológico, sin un mecanismo para filtrar efectos de lote, sexo, edad o patologías. Si estos sesgos no se corrigen, la proyección sobre el círculo queda deformada. En segundo lugar, su precisión decae cuando la distribución temporal de las muestras es muy desigual o presenta grandes huecos (muestreo disperso), un escenario frecuente en cohortes post-mortem. Por último, su implementación original en R es un *script* monolítico, poco modular y difícil de integrar, probar o paralelizar.

En conjunto, ningún método actual reúne simultáneamente interpretabilidad estadística, robustez frente a covariables y a muestreo disperso además de una arquitectura modular reutilizable, esta carencia motiva el presente trabajo.

1.4. Objetivos del trabajo

Las limitaciones anteriores motivan los objetivos de este trabajo, centrado en mejorar la metodología de estimación del orden temporal del algoritmo CIRCUST. El núcleo lo constituyen varias aportaciones metodológicas, que se apoyan en una re-implementación modular y eficiente del algoritmo.

Aportaciones metodológicas. Constituyen la contribución principal del trabajo:

1. **Modelo FMM robusto.** Implementar una versión más robusta del ajuste FMM que sustituye la función de pérdida por mínimos cuadrados (RSS) por un criterio de potencia penalizado: penaliza la rugosidad (curvatura) de la onda ajustada y pondera las muestras según su densidad temporal mediante un núcleo de von Mises. Con ello se reduce el sobreajuste al ruido y se mejora la estabilidad del ajuste, especialmente con pocas muestras o con un muestreo temporal irregular.
2. **Nueva metodología de sincronización.** Desarrollar un módulo dedicado a la sincronización del orden circular estimado con el tiempo biológico real. Parte de un

modo manual basado en genes ancla de fase conocida y avanza hacia una **selección automática (e híbrida) del ancla**, que reduce la intervención del usuario y la dependencia de un gen prefijado.

3. **Incorporación de la ordenación agregada.** Introducir en el algoritmo una técnica de **órdenes agregados** que consolida varias ordenaciones parciales en un único orden de consenso, mejorando la robustez y la estabilidad de la estimación final del orden temporal.
4. **Nueva metodología de validación.** Diseñar un marco de validación basado en la generación de datos sintéticos con orden temporal conocido e incorporar **nuevas fórmulas que cuantifican la correlación y la similitud** entre el orden estimado y el real, como un coeficiente de correlación circular robusto y una medida de concordancia entre las reconstrucciones, que permiten evaluar de forma sistemática la calidad de la estimación bajo distintos escenarios.

Objetivos de soporte. Dan sustento computacional a las aportaciones anteriores:

1. **Re-implementación modular en Python.** Reescribir el algoritmo CIRCUST original con una arquitectura modular, en la que cada etapa (preprocesamiento, CPCA, sincronización, selección de genes y estimación del orden) quede aislada en componentes independientes, reutilizables y fáciles de probar y extender.
2. **Optimización del rendimiento.** Reducir el tiempo de cómputo combinando la paralelización de las secciones más costosas del algoritmo con la vectorización de los cálculos numéricos.

1.5. Asignaturas relacionadas con el Trabajo de Fin de Grado

El desarrollo de este trabajo se apoya en competencias adquiridas en varias asignaturas del Grado en Estadística:

- **Inferencia Estadística I y II.** Proporcionan el marco para la validación de los resultados, la interpretación de los p-valores y la evaluación de modelos, aspectos centrales en la metodología de validación propuesta en este trabajo.
- **Análisis de Datos.** Aporta las técnicas de análisis multivariante y, en particular, el Análisis de Componentes Principales, que constituye la base del CPCA sobre el que se sustenta CIRCUST.

- **Regresión y Anova.** Tratan el efecto de las covariables y el estudio de las correlaciones, herramientas empleadas en el análisis y la corrección de los componentes principales.
- **Computación Estadística.** Fundamenta la programación y la implementación computacional del algoritmo, así como su optimización.

Capítulo 2

Metodología

2.1. El algoritmo CIRCUST

CIRCUST (*CIRC*ular-*robUST*) [14] es una metodología para reconstruir el orden temporal de los ritmos moleculares a partir de una matriz de expresión génica que carece de etiquetas temporales fiables. A diferencia de las aproximaciones de caja negra basadas en redes neuronales, CIRCUST se sustenta íntegramente en estadística clásica e interpretable: cada etapa del procedimiento admite una lectura estadística directa y produce magnitudes con significado biológico, como la fase asignada a cada muestra, el instante de máxima expresión de un gen (su pico), su amplitud o su grado de ritmicidad. Esta transparencia es, precisamente, la que permite en este trabajo intervenir y refinar etapas concretas del método sin necesidad de tratarlo como un bloque opaco.

Formalmente, se parte de una matriz de expresión $\mathbf{X} \in \mathbb{R}^{G \times n}$, en la que las G filas corresponden a genes (del orden de decenas de miles) y las n columnas a las muestras. El objetivo es doble: asignar a cada muestra i una fase $\varphi_i \in [0, 2\pi)$ que refleje su posición dentro del ciclo de 24 horas y, a partir del orden inducido por esas fases, caracterizar qué genes son rítmicos y cuándo alcanzan su pico. Conviene recordar (véase la Introducción) que la fase estimada es de naturaleza *circular*: queda determinada salvo una rotación global y un sentido de giro, que deben fijarse después mediante información biológica externa.

El método se organiza como una **secuencia de etapas bien delimitadas** (Figura 2.1), cada una con una entrada y una salida claras. Esta descomposición no es meramente expositiva: es la que da pie a la re-implementación modular descrita en la Sección 2.4, donde cada etapa se aísla en un componente independiente. A continuación se describe primero el flujo de trabajo de forma general y, después, se detallan sus dos pilares estadísticos, el Análisis de Componentes Principales Circular (CPCA) y el modelo FMM además de las aportaciones que CIRCUST introduce frente a los métodos previos.




Figura 2.1: Flujo de trabajo del algoritmo CIRCUST. Cada etapa transforma la salida de la anterior; los dos pilares estadísticos son el CPCA (etapa 2) y el modelo FMM, presente en las etapas 2, 4 y 5.

2.1.1. Visión general del flujo de trabajo

Las etapas que componen el algoritmo son las siguientes:

1. **Preprocesamiento:** Se descartan los genes poco informativos, es decir, aquellos con una fracción de valores nulos o ausentes por encima de un umbral especificado y se aplica una normalización *min-max* gen a gen, que lleva la expresión de cada gen al intervalo $[-1, 1]$. Con ello todos los genes contribuyen en una escala común y se evita que los de mayor varianza absoluta dominen el análisis posterior.
2. **Ordenación circular preliminar mediante CPCA:** Sobre un subconjunto reducido de *genes reloj* centrales se aplica un Análisis de Componentes Principales Circular [19]. Los dos primeros componentes proyectan cada muestra sobre el plano, y su posición angular respecto al origen proporciona un primer orden circular de todas las muestras. En esta misma etapa se detectan y eliminan muestras anómalas (*outliers*).
3. **Sincronización biológica:** El orden que devuelve el CPCA es correcto salvo una rotación y un sentido de giro arbitrarios. Esta etapa fija ambos grados de libertad anclando la escala a genes de fase conocida, de modo que el orden circular pase a estar alineado con el tiempo biológico real.

4. **Selección de genes TOP:** No todos los genes son rítmicos. Esta etapa identifica el subconjunto de genes que oscilan de forma fiable sobre el orden estimado, combinando dos criterios de bondad de ajuste (los modelos ORI y FMM) y exigiendo que sus picos cubran de forma razonable todo el ciclo.
5. **Estimación robusta del orden:** Para reducir la dependencia de un único subconjunto de genes, el orden se reestima K veces sobre remuestreos de los genes TOP y los resultados se consolidan en un orden de consenso. Esta etapa concentra una de las aportaciones del trabajo (que se detallan más adelante en este mismo capítulo) y se apoya en técnicas de agregación de órdenes circulares.

El resultado final es, por un lado, el **orden temporal de las muestras** (una fase $\varphi_i \in [0, 2\pi)$, traducible a horas) y, por otro, el **atlas circadiano** del tejido: para cada gen rítmico, sus parámetros estimados (amplitud, fase del pico, asimetría y bondad de ajuste).

2.1.2. Ordenación circular mediante CPCA

El primer pilar de CIRCUST es la obtención de un orden circular preliminar. En lugar de aplicar el Análisis de Componentes Principales (PCA) a los miles de genes de la matriz, CIRCUST lo restringe a un conjunto reducido de *genes reloj* bien caracterizados (por defecto, los doce genes del *core clock*: *PER1-3*, *CRY1-2*, *ARNTL*, *CLOCK*, *NR1D1*, *RORA*, *DBP*, *TEF* y *STAT3*). La razón es estadística: estos genes son rítmicos por construcción biológica, de modo que la principal fuente de variación entre sus perfiles es, justamente, la hora del día. Concentrar el PCA en ellos hace que las primeras componentes capturen la señal circadiana en vez del ruido de fondo.

A partir de la matriz normalizada de genes reloj, el CPCA extrae las dos primeras componentes principales y trata sus puntuaciones para cada muestra i como coordenadas en el plano, $(PC1_i, PC2_i)$. La posición angular de cada muestra respecto al origen define su fase preliminar:

$$\varphi_i = \text{atan2}(PC2_i, PC1_i) \text{ mód } 2\pi, \quad \rho_i = \sqrt{PC1_i^2 + PC2_i^2}, \quad (2.1)$$

donde ρ_i es la distancia al origen. Ordenando las muestras por φ_i se obtiene el orden circular preliminar. La interpretación geométrica es directa: si la expresión de los genes reloj oscila a lo largo del día, las muestras se disponen sobre una circunferencia y su ángulo refleja el momento del ciclo en que fueron tomadas. La distancia ρ_i actúa además como medida de fiabilidad: una muestra muy próxima al origen ($\rho_i \approx 0$) no tiene una fase bien definida y es candidata a *outlier*. CIRCUST descarta tales muestras combinando este criterio radial con un segundo criterio basado en residuos atípicos del ajuste rítmico, y

reejecuta el CPCA sobre los datos depurados. La formalización de la variante circular del PCA y la justificación de la proyección (2.1) se desarrollan en la Sección 2.3.

2.1.3. Sincronización con el tiempo biológico

El orden de la ecuación (2.1) es *circular*, y como tal queda indeterminado en dos aspectos: el origen ($\varphi = 0$ puede caer en cualquier punto del ciclo) y el sentido de avance (horario o antihorario son a priori equivalentes). Recuperar el tiempo biológico real exige fijar ambos. CIRCUST lo resuelve anclando la escala a genes de fase conocida: sitúa el pico de un *gen ancla* de fase bien caracterizada (por defecto *ARNTL*) en una posición de referencia de la escala, y emplea un segundo *gen de dirección* (por defecto *DBP*) para decidir la orientación, invirtiendo el sentido de giro cuando su pico cae en la mitad incorrecta del ciclo. Tras esta operación, el orden circular deja de ser relativo y pasa a estar sincronizado con el reloj biológico. Esta etapa es, además, una de las que el presente trabajo amplía, al avanzar hacia una selección automática del ancla (más adelante en este mismo capítulo).

2.1.4. Modelado de la ritmicidad: del Cosinor al modelo FMM

Una vez ordenadas las muestras, CIRCUST modela la curva de expresión de cada gen a lo largo del ciclo para decidir si es rítmico y, en caso afirmativo, estimar sus parámetros. El enfoque clásico para datos circadianos es el modelo **Cosinor** [25], que ajusta una senoide:

$$y(t) = M + A \cos(t - \phi) + \varepsilon, \quad (2.2)$$

donde M es el nivel medio (*mesor*), A la amplitud y ϕ la fase del pico (*acrófase*). Su limitación es la rigidez: la ecuación (2.2) impone una onda perfectamente simétrica, mientras que la expresión de muchos genes circadianos presenta picos agudos y valles anchos (o viceversa). Forzar una senoide sobre esos perfiles asimétricos sesga la estimación del pico, y la alternativa habitual es añadir armónicos, gana flexibilidad a costa de sobreajustar el ruido.

CIRCUST adopta en su lugar el modelo **FMM** (*Frequency Modulated Möbius*) [18], que introduce la asimetría sin renunciar a la interpretabilidad. El FMM deforma el argumento del coseno mediante una transformación de Möbius del círculo:

$$y(t) = M + A \cos\left(\beta + 2 \arctan\left(\omega \tan \frac{t-\alpha}{2}\right)\right) + \varepsilon, \quad (2.3)$$

con M el nivel medio, $A > 0$ la amplitud, α la localización de la región del pico, β un parámetro de forma y $\omega \in (0, 1]$ el parámetro que gobierna la *asimetría* de la onda. El comportamiento de ω es la clave del modelo: cuando $\omega = 1$ la transformación de Möbius se reduce a la identidad y la ecuación (2.3) recupera una onda cosenoidal simétrica, es

decir, el modelo Cosinor es un caso particular del FMM, mientras que al disminuir ω hacia 0 la onda se vuelve progresivamente más asimétrica y apuntada. De este modo, un único parámetro adicional permite cubrir desde el coseno simétrico hasta picos marcadamente agudos, conservando una lectura directa de la fase y la amplitud. Las propiedades de la transformación de Möbius y el procedimiento de estimación de (2.3) se detallan en la Sección 2.3.

2.1.5. Selección de genes rítmicos y orden robusto

La calidad del orden final depende de que se construya sobre genes genuinamente rítmicos. CIRCUST cuantifica la ritmicidad de cada gen mediante coeficientes de determinación R^2 , que miden la fracción de variabilidad explicada por el ajuste rítmico,

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}, \quad (2.4)$$

y combina dos modelos complementarios. Por un lado, el enfoque no paramétrico **ORI** (*Order Restricted Inference*) [20], que describe la oscilación mediante restricciones de desigualdad (un patrón unimodal de subida y bajada) sin imponer una forma funcional concreta, el modelo paramétrico FMM de la ecuación (2.3). Se seleccionan como **genes TOP** aquellos cuya expresión es bien explicada por ambos modelos (R^2 por encima de un umbral especificado en cada uno) y que, además, no producen ondas degeneradas (se exige un valor mínimo de ω). Para que el orden quede bien determinado a lo largo de todo el ciclo se impone también que los picos de los genes seleccionados cubran de forma equilibrada las distintas regiones de la circunferencia. El uso conjunto de un criterio no paramétrico (ORI) y otro paramétrico (FMM) hace la selección más exigente: solo sobreviven los genes cuyo carácter rítmico es robusto frente al tipo de modelo empleado.

Finalmente, para que la estimación no dependa de un subconjunto concreto de genes, CIRCUST reestima el orden sobre varios remuestreos de los genes TOP y consolida los resultados en un orden de consenso. El refinamiento de esta última etapa, mediante técnicas de agregación de órdenes circulares, constituye una de las aportaciones de este trabajo y se desarrolla más adelante en este mismo capítulo.

2.1.6. Aportaciones de CIRCUST frente a los métodos previos

Una vez descrito el flujo de trabajo, conviene situar a CIRCUST respecto a los métodos que lo precedieron, que se detallan en la Sección 2.2. Las diferencias no son solo de rendimiento, sino de filosofía e implementación y pueden agruparse en cuatro aportaciones.

Transparencia e interpretabilidad estadística. La aportación más característica de CIRCUST es que cada etapa es un procedimiento estadístico con una lectura explícita.

Las componentes de la ecuación (2.1) son las direcciones de máxima varianza de los genes reloj, los parámetros de la ecuación (2.3) son la amplitud, la fase y la asimetría de cada gen y el R^2 de la ecuación (2.4) es una bondad de ajuste interpretable. Frente a ello, los métodos basados en *autoencoders* como CYCLOPS o PENN comprimen la señal en un espacio latente cuyos pesos no admiten una interpretación biológica directa: aciertan a ordenar las muestras, pero no ofrecen una trazabilidad estadística de *por qué* lo hacen. Esta transparencia tiene además una consecuencia práctica determinante para este trabajo: permite intervenir, sustituir o reforzar etapas concretas (por ejemplo, la función de pérdida del ajuste FMM o la regla de sincronización) sin desmontar el método completo.

Descomposición modular del problema. CIRCUST aborda la reconstrucción del orden temporal descomponiéndola en subproblemas estadísticos bien delimitados; reducción de dimensionalidad, sincronización, selección de genes y agregación de órdenes. En lugar de resolverla de un solo paso con un modelo monolítico, como hace un autoencoder entrenado de extremo a extremo. Esta modularidad conceptual facilita razonar sobre cada etapa por separado, diagnosticar dónde falla la estimación y reemplazar componentes de forma aislada. Es también el principio que vertebra la re-implementación desarrollada en este trabajo (Sección 2.4), que materializa cada etapa en un módulo independiente, frente al *script* monolítico de la versión original.

Flexibilidad del modelo FMM frente a la rigidez del Cosinor. A diferencia del enfoque clásico Cosinor (ecuación (2.2)), que impone una senoide simétrica, el modelo FMM (ecuación (2.3)) captura los picos asimétricos característicos del transcriptoma a través del parámetro ω , recuperando el coseno como caso particular ($\omega = 1$). Logra así un equilibrio que los armónicos múltiples no alcanzan: gana flexibilidad para representar formas de onda complejas sin incurrir en el sobreajuste que provoca añadir términos, y conserva una interpretación directa de la fase del pico, que es precisamente la magnitud de interés biológico.

Sincronización explícita con el tiempo biológico. CIRCUST incorpora una etapa dedicada a alinear el orden circular indeterminado en origen y sentido con el reloj biológico, mediante genes ancla de fase conocida (Sección 2.1.3). Este paso resuelve de forma explícita y trazable un problema que los métodos previos tratan de manera implícita o lo dejan sin abordar: los *autoencoders* (CYCLOPS, PENN) entregan una fase relativa que requiere realineamiento posterior, y CHIRAL afronta la coherencia entre tejidos de un mismo donante pero no la sincronización con un marco temporal absoluto a partir de genes de referencia. Disponer de esta etapa como un componente propio es, además, lo que hace viable extenderla hacia una selección automática del ancla, una de las aportaciones

de este trabajo.

Otras observaciones. Conviene señalar, por último, dos rasgos transversales. El primero es la *robustez*, recogida en el propio nombre del método (*CIRCular-robUST*): la detección de *outliers* en la etapa de CPCA y la reestimación del orden sobre múltiples remuestreos de genes buscan que el resultado no dependa de muestras anómalas ni de una selección concreta de genes. El segundo es su *aplicabilidad en escenarios de pocos datos*: al no requerir el entrenamiento de una red neuronal, CIRCUST no sufre el sobreajuste típico de esos modelos cuando el número de muestras es reducido, y opera sobre un solo tejido sin necesitar la estructura multi-tejido que CHIRAL aprovecha. Estos rasgos lo hacen especialmente adecuado para las cohortes pequeñas y heterogéneas habituales en transcriptómica humana.

2.2. Otros métodos de estimación del orden temporal

CIRCUST no es el único método que aborda la reconstrucción del orden temporal. Conviene situarlo frente a las principales alternativas, presentadas ya de forma previa en la Introducción, ahora con algo más de detalle pero sin entrar en su formulación completa. El propósito es entender en qué se distinguen, qué supuestos hacen y dónde residen sus limitaciones, lo que justifica las aportaciones de este trabajo.

Una primera distinción separa los enfoques *supervisados* de los *no supervisados*. Los métodos supervisados como ZeitZeiger [26] o TimeSignature [27] aprenden la relación entre expresión y hora del día a partir de un conjunto de entrenamiento con etiquetas temporales conocidas y predicen después la fase de muestras nuevas. Son precisos cuando se dispone de ese material de entrenamiento, pero resultan inaplicables al escenario que motiva este trabajo: en tejido humano post-mortem no existen etiquetas temporales fiables con las que entrenar. Por ello el interés se concentra en los métodos *no supervisados*, que reconstruyen el orden a partir únicamente de la estructura interna de los datos de expresión. Dentro de estos, la familia dominante es la basada en redes neuronales, junto a la de CIRCUST, de base estadística clásica.

2.2.1. Métodos basados en *autoencoders*: CYCLOPS y PENN

CYCLOPS (*CYclic Ordering by Periodic Structure*) [21] es el método de referencia de esta familia. Su punto de partida es una observación clásica sobre los datos de expresión periódicos: al descomponerlos en valores singulares se obtienen unos patrones característicos (los *eigengenes*), y los primeros de ellos se comportan como oscilaciones sinusoidales desfasadas entre sí. Representadas dos de esas oscilaciones una frente a otra, las muestras se disponen aproximadamente sobre una *ellipse*, y su posición angular sobre

esa elipse proporciona el orden de las muestras dentro del ciclo, con independencia de la hora real de recogida.

CYCLOPS aprende esa estructura elíptica mediante un *autoencoder*: una red neuronal entrenada para reproducir en su salida la misma entrada que recibe, obligada a comprimir la información en una capa intermedia (*cuello de botella*) de dimensión reducida. La particularidad de CYCLOPS es que ese cuello de botella es un *nodo circular*, implementado como dos neuronas acopladas (u_i, v_i) que se proyectan sobre el círculo unidad; la fase asignada a cada muestra i es entonces el ángulo

$$\varphi_i = \text{atan2}(v_i, u_i) \in [0, 2\pi). \quad (2.5)$$

La red se entrena minimizando el error de reconstrucción entre su entrada y su salida; tras varios reinicios aleatorios se conserva la solución con menor error. El paralelismo con CIRCUST es notable, ambos reducen la dimensionalidad y proyectan las muestras sobre una circunferencia para leer su fase como un ángulo (compárese con la ecuación (2.1)), pero CYCLOPS realiza esa proyección de forma no lineal y no interpretable, mientras que el CPCA lo hace con una transformación lineal trazable.




Figura 2.2: Arquitectura resumida del *autoencoder* de cuello de botella circular empleado en CYCLOPS. La red comprime la expresión en un único nodo circular, cuya fase ordena las muestras.

Conviene señalar tres rasgos de CYCLOPS que condicionan su uso. Primero, requiere que las muestras cubran todo el ciclo para que la elipse quede bien definida y, en la práctica, un número elevado de ellas (sus autores estiman que del orden de varios cientos). Segundo, el orden que produce es *relativo*: no fija ni el origen ni el sentido, por lo que necesita información externa para anclarlo al tiempo biológico (en sus aplicaciones, los

autores fijan el origen con la fase media de un grupo de factores de transcripción de fase conocida). Tercero, al derivarse la fase de los propios datos de expresión, los contrastes de ritmicidad posteriores tienden a ser demasiado liberales, lo que obliga a usar umbrales de significación más estrictos.

Su evolución, **CYCLOPS 2.0** [22], mantiene esta arquitectura y añade una **corrección de covariables**: mediante una codificación *multi-hot* que indica qué factores (tejido, lote de laboratorio, características del paciente) afectan a cada muestra, ajusta los datos de entrada para atenuar esas fuentes de variación ajenas al ritmo antes de comprimirlos en el cuello de botella, y revierte el ajuste tras la reconstrucción.

PENN (*Phase Estimation Neural Network*) [23] comparte el esqueleto de CYCLOPS reducción previa de la dimensionalidad mediante componentes principales y un *autoencoder* con un nodo circular que asigna la fase según la ecuación (2.5), pero modifica el criterio de entrenamiento. CYCLOPS solo minimiza el error de reconstrucción y, por tanto, no aprovecha que la expresión de los genes rítmicos debe describir una curva periódica al ordenarse por fase. PENN incorpora esa información añadiendo un segundo término a la función de pérdida, que exige que cada gen se ajuste a una onda cosenoidal cuando las muestras se colocan en el orden estimado:

$$\mathcal{L} = \underbrace{\frac{1}{m} \sum_{i=1}^m \|x_i - \hat{x}_i\|^2}_{\text{reconstrucción}} + \lambda \underbrace{\frac{1}{m} \sum_{i=1}^m \frac{1}{n} \sum_{g=1}^n \left(x_i^{(g)} - \hat{y}_i^{(g)}\right)^2}_{\text{ajuste a coseno}}, \quad (2.6)$$

donde $\hat{x}_i$ es la reconstrucción de la muestra x_i , $\hat{y}_i^{(g)}$ es el valor predicho para el gen g por una curva cosenoidal de la fase estimada y λ pondera ambos objetivos. Esta regularización geométrica estabiliza la estimación y, según sus autores, mejora la precisión del orden frente a CYCLOPS sin alterar la arquitectura básica. Aun así, comparte con él la naturaleza de caja negra: la fase se obtiene de los pesos de una red, sin una lectura estadística directa.

2.2.2. Métodos para datos multi-tejido: CHIRAL

Por último, **CHIRAL** [24] responde a un escenario distinto: el de los grandes atlas multi-tejido, como GTEx, en los que de cada donante se dispone de muestras de varios órganos. En lugar de tratar todos los tejidos como un único bloque, CHIRAL opera de forma jerárquica: estima primero una fase interna específica de cada tejido a partir de sus genes reloj y la integra después, para los tejidos de un mismo donante, en una fase interna global del individuo. Así separa la variabilidad propia de cada tejido de la fase circadiana sistémica del donante. Su contrapartida es que esa misma fortaleza lo hace dependiente de la estructura multi-tejido: pierde eficacia en estudios de un solo tejido o en cohortes pequeñas, donde no existe esa jerarquía sobre la que apoyar la estimación.

2.3. Fundamentos matemáticos de CPCA y FMM

Las secciones anteriores han descrito CIRCUST y sus alternativas a un nivel operativo. Esta sección desarrolla las herramientas matemáticas que sustentan el método y, con ellas, las aportaciones de las secciones siguientes. Se parte de unos preliminares de estadística circular que fijan la notación, se formaliza después la ordenación circular mediante CPCA y, por último, se presentan los dos modelos de ritmicidad que emplea CIRCUST: el paramétrico FMM y el no paramétrico ORI.

2.3.1. Preliminares de estadística circular

El rasgo distintivo del problema es que el tiempo se representa sobre una circunferencia, no sobre una recta. Un instante del ciclo se codifica como un ángulo $\theta \in [0, 2\pi)$, identificado con el punto $(\cos \theta, \sin \theta)$ del círculo unidad; la hora 0 y la hora 24 son el mismo punto. Esto obliga a sustituir los estadísticos lineales habituales por sus análogos circulares.

Dirección media y concentración. La media aritmética de un conjunto de ángulos no es un buen resumen (el promedio de 1° y 359° debería ser 0° , no 180°). En su lugar se promedian los vectores unitarios asociados. Dados $\theta_1, \dots, \theta_n$, se define el *vector resultante medio* a partir de

$$C = \sum_{i=1}^n \cos \theta_i, \quad S = \sum_{i=1}^n \sin \theta_i, \quad (2.7)$$

de donde la *dirección media* y la *longitud resultante media* son

$$\bar{\theta} = \text{atan2}(S, C), \quad \bar{R} = \frac{\sqrt{C^2 + S^2}}{n} \in [0, 1]. \quad (2.8)$$

La dirección media $\bar{\theta}$ es el centro del conjunto de ángulos, y $\bar{R}$ mide su *concentración*: vale 1 cuando todos los ángulos coinciden y se acerca a 0 cuando se reparten de forma uniforme por el círculo.

Orden circular. Ordenar n muestras según su ángulo produce un *orden circular*: una disposición cíclica en la que no hay primero ni último, sino solo posiciones relativas sobre la circunferencia. Dos consecuencias son centrales para todo el trabajo. Primera, el orden circular queda determinado únicamente *salvo una rotación* (el origen es arbitrario) y *una reflexión* (el sentido de giro, horario o antihorario, es a priori intercambiable), fijar ambos grados de libertad es el problema de sincronización, del que se ocupa la Sección 2.6. Segunda, la distancia natural entre dos ángulos no es $|\alpha - \beta|$, sino la distancia geodésica sobre el círculo,

$$d(\alpha, \beta) = \min(|\alpha - \beta|, 2\pi - |\alpha - \beta|) \in [0, \pi], \quad (2.9)$$

que es la que emplean las técnicas de agregación y validación de las Secciones 2.7 y 2.8.

Otras herramientas de estadística circular se introducen más adelante, allí donde se emplean: la distribución de von Mises como núcleo de ponderación temporal en la Sección 2.5 y los coeficientes de correlación circular para evaluar reconstrucciones del orden en la Sección 2.8.

2.3.2. Ordenación circular mediante CPCA

El primer pilar de CIRCUST es el Análisis de Componentes Principales Circular (CPCA) [19], un método previo que el algoritmo adopta sin modificarlo. Su función es reducir la dimensionalidad de la expresión de los genes reloj para obtener un orden circular de las muestras. Para ello aplica un Análisis de Componentes Principales a esa submatriz, toma los dos primeros componentes como coordenadas de cada muestra en el plano y lee su posición angular como fase, según la proyección ya presentada en la ecuación (2.1).

La razón de que esa proyección recupere el tiempo se entiende a partir de la forma de la señal. Si un gen reloj oscila de modo aproximadamente sinusoidal a lo largo del día, su expresión en una muestra tomada en el instante t puede escribirse como

$$x_g(t) = a_g \cos(t - \phi_g) = a_g \cos \phi_g \cos t + a_g \sin \phi_g \sin t, \quad (2.10)$$

esto es, como una combinación lineal de las mismas dos señales, $\cos t$ y $\sin t$, sea cual sea su fase ϕ_g . En ausencia de ruido, la matriz de los genes reloj tiene por tanto rango dos y toda su información esencial vive en un plano. El Análisis de Componentes Principales identifica precisamente ese plano de máxima variación. Sus dos primeros componentes se comportan como dos oscilaciones en cuadratura, de manera que las muestras se sitúan sobre una elipse y su ángulo reproduce el instante del ciclo.

De ahí la proyección sobre el círculo unidad de la ecuación (2.1). La fase de cada muestra es su ángulo φ_i y su distancia al origen ρ_i mide la fiabilidad de esa fase. Ordenar las muestras por φ_i produce el orden circular preliminar. Las muestras con ρ_i próximo a cero carecen de una fase bien definida y se tratan como *outliers*. El problema que resuelve el CPCA es, en consecuencia, doble. Convierte una matriz de expresión de alta dimensión en un único orden circular interpretable y proporciona a la vez un criterio de calidad por muestra.

2.3.3. El modelo FMM

El segundo pilar es el modelo de ritmicidad. El enfoque clásico, el Cosinor [25] de la ecuación (2.2), ajusta una senoide simétrica, su rigidez sesga la estimación cuando los genes presentan picos asimétricos y la alternativa de añadir armónicos tiende a sobreajustar el ruido. CIRCUST adopta en su lugar el modelo FMM (*Frequency Modulated Möbius*)

[18], también un método previo del que aquí solo interesa su aportación.

El FMM, presentado en la ecuación (2.3), deforma el argumento del coseno mediante una transformación de Möbius del círculo, gobernada por un parámetro de asimetría ω . Con ello ataca justamente el problema del Cosinor: captura formas de onda asimétricas y apuntadas (recuperando el coseno simétrico como caso particular, $\omega = 1$) sin renunciar a una interpretación directa de sus parámetros; nivel medio, amplitud, fase del pico y asimetría. Y sin el sobreajuste asociado a los modelos multiarmónicos. El modelo se ajusta por mínimos cuadrados, es precisamente esa función de pérdida la que la Sección 2.5 sustituye por un criterio penalizado más robusto, que constituye una de las aportaciones de este trabajo.

2.3.4. Inferencia con restricciones de orden (ORI)

El modelo FMM impone una forma funcional concreta. Como contrapeso, CIRCUST emplea además un criterio *no paramétrico* que solo asume que la expresión sigue un patrón *unimodal* a lo largo del ciclo (sube hasta un máximo y luego baja), sin fijar ninguna ecuación. Es la Inferencia con Restricciones de Orden (ORI) [20]: dada la expresión ordenada por fase, se busca la curva que mejor la ajusta sujeta a la restricción de unimodalidad, mediante regresión isotónica (algoritmo *pool adjacent violators* PAVA). La calidad del ajuste se cuantifica de nuevo con un coeficiente de determinación,

$$R_{\text{ORI}}^2 = 1 - \frac{\text{SSE}_{\text{unimodal}}}{\text{SSE}_{\text{constante}}}, \quad (2.11)$$

que compara el error del ajuste unimodal con el de un modelo plano (sin ritmo). Disponer de un criterio paramétrico (FMM) y otro no paramétrico (ORI) hace más exigente la selección de genes rítmicos descrita en la Sección 2.1.5, un gen solo se considera fiable si ambos coinciden en que oscila, lo que reduce el riesgo de seleccionar artefactos dependientes del modelo.

2.4. Mejora de CIRCUST: implementación modular y eficiencia

Las aportaciones metodológicas de las secciones siguientes se apoyan en un objetivo de soporte que conviene presentar antes, la re-implementación de CIRCUST en Python. La versión original es un *script* monolítico en R, en el que todas las etapas comparten un mismo flujo de código y resulta difícil de probar, extender o paralelizar (Sección 1.3.1). La re-implementación persigue dos metas complementarias. La primera es una arquitectura modular que aisle cada etapa del algoritmo. La segunda es una mejora del rendimiento que aproveche el ecosistema numérico de Python. Ambas se describen a continuación.

2.4.1. Estructura modular

La idea principal es traducir la descomposición conceptual del método (Figura 2.1) en una descomposición real del código. Cada etapa del algoritmo se encapsula en un componente independiente, implementado como una clase con un método `run()` que recibe la salida de la etapa anterior y devuelve un objeto de resultado bien definido. Así, el preprocesamiento, la selección de genes reloj, el CPCA, la sincronización, la selección de genes TOP y la estimación robusta del orden viven cada uno en su propio módulo, y un orquestador se limita a encadenarlos. Los datos que circulan entre etapas no son variables sueltas, sino estructuras de resultado explícitas, lo que hace inequívoco qué produce y qué consume cada componente.

Esta separación se extiende a los modelos de ritmicidad, que se agrupan en un subpaquete propio bajo una interfaz común. Todos los modelos (el FMM en sus variantes base y robusta, el Cosinor y el ORI) comparten un mismo contrato, una clase base abstracta con un método `fit()` y un contenedor de resultados homogéneo. De este modo, cualquier punto del algoritmo que necesite ajustar una curva puede usar uno u otro modelo sin cambios en el resto del código, lo que resulta esencial para introducir el FMM robusto de la Sección 2.5 como una pieza intercambiable.

La arquitectura prevé además varios puntos de configuración que permiten alterar el comportamiento del algoritmo sin reescribirlo. Se puede seleccionar la variante del modelo FMM, el método con que se elige el orden robusto, la técnica de agregación de órdenes o el conjunto de genes reloj de partida, todo ello como opciones y no como modificaciones del código. Por último, la implementación separa el cálculo de las tareas accesorias. El núcleo de cómputo no se ocupa de la entrada y salida, que se limita a volcar los resultados a ficheros, y tanto la visualización como la validación residen en módulos aparte. El conjunto se distribuye como un paquete instalable y se acompaña de pruebas unitarias.

El resultado es un sistema testable, reutilizable y extensible, en el que una etapa puede probarse de forma aislada, reemplazarse por una variante o paralelizarse sin afectar a las demás. Es justamente lo que el *script* monolítico original no permitía.

2.4.2. Eficiencia en Python

Python es un lenguaje interpretado y, por sí solo, más lento que R o C en los bucles numéricos intensivos. La eficiencia de esta implementación descansa, por tanto, en tres estrategias que evitan ejecutar esos bucles en Python puro.

La primera es la **vectorización**. Las operaciones se expresan como álgebra matricial sobre arreglos completos en lugar de bucles elemento a elemento, y se delegan en bibliotecas numéricas compiladas. El CPCA, por ejemplo, se reduce a una descomposición en valores singulares resuelta por rutinas optimizadas de LAPACK, y el paso lineal del ajuste FMM es un problema de mínimos cuadrados igualmente vectorizado.

La segunda es la **compilación al vuelo** (JIT). La parte más costosa del ajuste FMM es la búsqueda en rejilla, en la que el modelo y su función objetivo se evalúan miles de veces por cada gen. Esas funciones internas se compilan a código máquina con Numba, lo que elimina la sobrecarga del intérprete en el bucle crítico. La misma técnica se aplica al ajuste ORI. De forma opcional, y dado que cada punto de la rejilla es independiente de los demás, la búsqueda puede ejecutarse en GPU mediante CUDA cuando hay una disponible.

La tercera es la **paralelización**, que se aplica en los dos lugares donde el trabajo se reparte de forma natural. Por un lado, los ajustes de los distintos genes en la selección de genes TOP se distribuyen entre los núcleos del procesador. Por otro, las K repeticiones de la estimación robusta del orden, que son independientes entre sí, se ejecutan en paralelo. El tipo de paralelismo se elige según la naturaleza del cálculo. Cuando el trabajo libera el bloqueo global del intérprete, como ocurre con el FMM robusto al apoyarse en rutinas BLAS y en núcleos compilados con Numba, basta con hilos que comparten en memoria las matrices ya precalculadas y se evita el coste de serializar datos entre procesos. En caso contrario se recurre a procesos independientes.

A estas tres estrategias se añade el **precálculo y reutilización** de resultados intermedios. En el FMM robusto, la rejilla y las matrices auxiliares se calculan una sola vez y se reutilizan para todos los genes, y el parámetro de penalización se calibra una única vez y se propaga a las etapas posteriores en lugar de recomputarse. El efecto conjunto de estas decisiones es una reducción sustancial del tiempo de cómputo frente a una traducción directa del algoritmo original.

2.5. Modelo FMM robusto

La primera aportación metodológica del trabajo es una versión robusta del ajuste FMM, concebida para estabilizar la estimación cuando los datos son escasos, ruidosos o de muestreo temporal irregular, condiciones habituales en las cohortes post-mortem humanas. La idea es modificar el modo en que se ajusta el modelo de la Sección 2.3.3, sin alterar su forma funcional, de manera que el ajuste resulte menos sensible al ruido y al desequilibrio en la distribución de las muestras.

El ajuste FMM base estima los parámetros por mínimos cuadrados, esto es, minimizando la suma de residuos al cuadrado. Ese criterio presenta dos debilidades cuando los datos son escasos o ruidosos. La primera es que tiende a sobreajustar el ruido, produciendo ondas muy apuntadas que se ciñen a las observaciones concretas pero no al ritmo subyacente. La segunda es que trata todas las muestras por igual, de modo que las regiones del ciclo con muchas muestras dominan el ajuste mientras que las poco muestreadas apenas influyen, un problema frecuente cuando el muestreo temporal es irregular. El FMM robusto ataca ambas debilidades a la vez. Sustituye la función de pérdida por un criterio de

potencia penalizado y pondera las muestras según su densidad temporal.

Ponderación por densidad temporal. Para que ninguna zona del ciclo pese más que otra por el mero hecho de estar más muestreada, a cada muestra i se le asigna un peso inversamente proporcional a la densidad de muestras en su instante. Esa densidad se estima con un núcleo de von Mises (la distribución circular de la ecuación (??)) centrado en cada muestra,

$$\hat{f}(t) = \frac{1}{n 2\pi I_0(\kappa)} \sum_{j=1}^n \exp(\kappa \cos(t - t_j)), \quad w_i \propto \frac{1}{\hat{f}(t_i)}, \quad (2.12)$$

con los pesos reescalados para que $\sum_i w_i = n$. El parámetro de concentración κ se elige de forma automática por validación cruzada dejando uno fuera. Así, las muestras situadas en tramos del ciclo poco representados reciben más peso, lo que compensa los muestreos irregulares.

Criterio de potencia penalizado. El núcleo de la propuesta es reemplazar la minimización del error por la maximización de un criterio que premia el ajuste y castiga la complejidad de la onda. Fijados los parámetros no lineales (α, ω) , que determinan la fase de Möbius $\varphi_i = \varphi(t_i; \alpha, \omega)$, el criterio es

$$J(\alpha, \omega) = P(\alpha, \omega) - \lambda g(\omega) R(\alpha, \omega). \quad (2.13)$$

El primer término, P , es la potencia de un periodograma ponderado en la forma de Lomb–Scargle,

$$P(\alpha, \omega) = \frac{u^2 + v^2}{D}, \quad \text{con} \quad \begin{aligned} u &= \sum_i w_i (x_i - \bar{x}_w) \cos \varphi_i, \\ v &= \sum_i w_i (x_i - \bar{x}_w) \sin \varphi_i, \\ D &= \sum_i w_i \cos^2 \varphi_i + \sum_i w_i \sin^2 \varphi_i, \end{aligned} \quad (2.14)$$

donde $\bar{x}_w$ es la media ponderada de la expresión. La potencia P mide cuánta señal rítmica captura la onda definida por (α, ω) y desempeña el papel que en el FMM base tenía el ajuste por mínimos cuadrados. De hecho, en ausencia de pesos y penalización, maximizar P equivale a minimizar la suma de residuos al cuadrado. El segundo término penaliza la *rugosidad*. La cantidad $R(\alpha, \omega)$ mide la curvatura de la onda ajustada a través de las segundas derivadas de sus componentes, de manera que las ondas muy onduladas o apuntadas, propias del sobreajuste, reciben un castigo mayor. El factor $g(\omega) = (\omega_0/(\omega + \omega_0))^p$ refuerza esa penalización a medida que ω disminuye, es decir, precisamente en

las formas más apuntadas, que son las más propensas a sobreajustar. El parámetro λ gradúa el equilibrio entre ajuste y suavidad. Una vez localizado el máximo de J sobre una rejilla de valores de (α, ω) , con un refinamiento local posterior, los parámetros lineales restantes (mesor, amplitud y forma) se obtienen en forma cerrada por mínimos cuadrados ponderados.

Calibración de la penalización. Queda por fijar λ . Un valor demasiado pequeño no corrige el sobreajuste, y uno demasiado grande aplana ritmos reales. La propuesta lo calibra de forma automática bajo la hipótesis nula de ausencia de ritmo. Se simulan numerosas réplicas de datos planos, sin más señal que el ruido, y para cada valor candidato de λ se resume un cuantil alto del estadístico que detecta ondas apuntadas espurias. La curva de ese cuantil frente a λ decrece a medida que se penaliza más, y se elige el valor situado en su codo, el punto a partir del cual aumentar la penalización ya apenas reduce los picos falsos. Este λ calibrado se calcula una sola vez sobre el conjunto de datos y se reutiliza en todas las etapas que ajustan un FMM, como se anticipó en la Sección 2.4.2.

Estabilidad numérica. Por último, la implementación evalúa la fase de Möbius sin calcularla de forma explícita. En lugar de obtener φ y arriesgar la singularidad que la tangente introduce cuando $t - \alpha = \pi$, calcula directamente $\cos \varphi$ y $\sin \varphi$ mediante identidades del ángulo doble, cuyo denominador es una suma de cuadrados siempre positiva. Esto hace el ajuste numéricamente estable en todo el ciclo.

2.6. El problema de sincronización de órdenes circulares

2.6.1. Formulación del problema y los $2n$ órdenes

(En desarrollo...)

2.6.2. Algoritmo de minimización para la sincronización

(En desarrollo...)

Información adicional

(En desarrollo...)

Métricas de evaluación

(En desarrollo...)

2.7. Ordenación agregada: orden de consenso

(En desarrollo...)

2.8. Marco de validación y métricas de similitud

(En desarrollo...)

Capítulo 3

Resultados y Simulaciones

(En desarrollo...)

Capítulo 4

Conclusiones y Trabajo Futuro

(En desarrollo...)

Bibliografía

- [1] Takahashi, J. S. (2017). *Transcriptional architecture of the mammalian circadian clock*. Nature Reviews Genetics, 18(3):164–179. <https://doi.org/10.1038/nrg.2016.150>
- [2] Klein, D. C., Moore, R. Y., y Reppert, S. M. (Eds.) (1991). *Suprachiasmatic Nucleus: The Mind's Clock*. Oxford University Press, Nueva York.
- [3] Czeisler, C. A., y Klerman, E. B. (1999). *Circadian and sleep-dependent regulation of hormone release in humans*. Recent Progress in Hormone Research, 54:97–130.
- [4] Roenneberg, T., y Merrow, M. (2016). *The Circadian Clock and Human Health*. Current Biology, 26(10):R432–R443. <https://doi.org/10.1016/j.cub.2016.04.011>
- [5] Zhang, R., Lahens, N. F., Ballance, H. I., Hughes, M. E., y Hogenesch, J. B. (2014). *A circadian gene expression atlas in mammals: Implications for biology and medicine*. Proceedings of the National Academy of Sciences of the United States of America, 111(45):16219–16224. <https://doi.org/10.1073/pnas.1408886111>
- [6] Hughes, M. E., DiTacchio, L., Hayes, K. R., Vollmers, C., Pulivarthy, S., Baggs, J. E., Panda, S., y Hogenesch, J. B. (2009). *Harmonics of Circadian Gene Transcription in Mammals*. PLoS Genetics, 5(4):e1000442. <https://doi.org/10.1371/journal.pgen.1000442>
- [7] Sulli, G., Manoogian, E. N. C., Taub, P. R., y Panda, S. (2018). *Training the Circadian Clock, Clocking the Drugs, and Drugging the Clock to Prevent, Manage, and Treat Chronic Diseases*. Trends in Pharmacological Sciences, 39(9). <https://doi.org/10.1016/j.tips.2018.07.003>
- [8] Sahar S, Sassone-Corsi P. *Metabolism and cancer: the circadian clock connection*. Nat Rev Cancer. 2009 Dec;9(12):886-96. <https://doi.org/10.1038/nrc2747>. PMID: 19935677.
- [9] Antoch, M. P., y Kondratov, R. V. (2013). *Pharmacological modulators of the circadian clock as potential therapeutic drugs: focus on genotoxic/anticancer therapy*. Handbook of Experimental Pharmacology, 217. https://doi.org/10.1007/978-3-642-25950-0_12

- [10] Hesse, J., Martinelli, J., Aboumanify, O., Ballesta, A., y Relógio, A. (2021). *A mathematical model of the circadian clock and drug pharmacology to optimize irinotecan administration timing in colorectal cancer*. Computational and Structural Biotechnology Journal, 19:5170–5183. <https://doi.org/10.1016/j.csbj.2021.08.051>
- [11] Ueda, H. R., Hayashi, S., Chen, W., Sano, M., Machida, M., Shigeyoshi, Y., Iino, M., y Hashimoto, S. (2005). *System-level identification of transcriptional circuits underlying mammalian circadian clocks*. Nature Genetics, 37(2):187–192. <https://doi.org/10.1038/ng1504>
- [12] Panda, S., Antoch, M. P., Miller, B. H., Su, A. I., Schook, A. B., Straume, M., Schultz, P. G., Kay, S. A., Takahashi, J. S., y Hogenesch, J. B. (2002). *Coordinated Transcription of Key Pathways in the Mouse by the Circadian Clock*. Cell, 109(3):307–320. [https://doi.org/10.1016/S0092-8674\(02\)00722-5](https://doi.org/10.1016/S0092-8674(02)00722-5)
- [13] GTEx Consortium (2020). *The GTEx Consortium atlas of genetic regulatory effects across human tissues*. Science, 369(6509):1318-1330. <https://doi.org/10.1126/science.aaz1776>
- [14] Larriba, Y., Mason, I. C., Saxena, R., Scheer, F. A. J. L., y Rueda, C. (2023). *CIR-CUST: A novel methodology for temporal order reconstruction of molecular rhythms; validation and application towards a daily rhythm gene expression atlas in humans*. PLOS Computational Biology, 19(9):e1011510. <https://doi.org/10.1371/journal.pcbi.1011510>
- [15] Brown, S. A., Fleury-Olela, F., Nagoshi, E., Hauser, C., Juge, C., Meier, C. A., Chicheportiche, R., Dayer, J.-M., Albrecht, U., y Schibler, U. (2005). *The Period Length of Fibroblast Circadian Gene Expression Varies Widely Among Human Individuals*. PLoS Biology, 3(10):e338. <https://doi.org/10.1371/journal.pbio.0030338>
- [16] Walker, W. H., Walton, J. C., DeVries, A. C., y Nelson, R. J. (2020). *Circadian rhythm disruption and mental health*. Translational Psychiatry, 10(1):28. <https://doi.org/10.1038/s41398-020-0694-0>
- [17] Zhu, Y., Wang, L., Yin, Y., y Yang, E. (2017). *Systematic Analysis of Gene Expression Patterns Associated with Postmortem Interval in Human Tissues*. Scientific Reports, 7(1):5435. <https://doi.org/10.1038/s41598-017-05882-0>
- [18] Rueda, C., Larriba, Y., y Peddada, S. (2019). *Frequency Modulated Möbius Model Accurately Predicts Rhythmic Signals in Biological and Physical Sciences*. Scientific Reports, 9:18701. <https://doi.org/10.1038/s41598-019-54569-1>
- [19] Scholz, M. (2007). *Analysing Periodic Phenomena by Circular PCA*. En *Bioinformatics Research and Development (BIRD 2007)* (pp. 38-47). Springer.

- [20] Larriba, Y., Rueda, C., Fernández, M. A., y Peddada, S. D. (2016). *Order restricted inference for oscillatory systems for detecting rhythmic signals*. Nucleic Acids Research, 44(22):e163. <https://doi.org/10.1093/nar/gkw771>
- [21] Anafi, R., Francey, L., Hogenesch, J., y Kim, J. (2017). *CYCLOPS reveals human transcriptional rhythms in health and disease*. Proceedings of the National Academy of Sciences of the United States of America, 114(20):5312–5317. <https://doi.org/10.1073/pnas.1619320114>
- [22] Hammarlund, J. A. (2025). *CYCLOPS 2.0: improving and applying circadian phase reconstruction in confounded datasets* (Tesis doctoral). Drexel University, Filadelfia, Pensilvania.
- [23] Ansary Ogholbake, A., y Cheng, Q. (2023). *PENN: Phase Estimation Neural Network on Gene Expression Data*. En *Deep Learning, Big Data and Blockchain (DBB 2023)*. Lecture Notes in Networks and Systems, vol. 768, pp. 59–67. Springer. https://doi.org/10.1007/978-3-031-42317-8_5
- [24] Talamanca, L., et al. (2023). *Sex-dimorphic and age-dependent organization of 24-hour gene expression rhythms in humans*. Science, 379(6631):478–483. <https://doi.org/10.1126/science.add0846>
- [25] Cornelissen, G. (2014). *Cosinor-based rhythmometry*. Theoretical Biology & Medical Modelling, 11:16. <https://doi.org/10.1186/1742-4682-11-16>
- [26] Hughey, J. J., Hastie, T., y Butte, A. J. (2016). *ZeitZeiger: supervised learning for high-dimensional data from an oscillatory system*. Nucleic Acids Research, 44(8):e80. <https://doi.org/10.1093/nar/gkw030>
- [27] Braun, R., Kath, W. L., Iwanaszko, M., Kula-Eversole, E., Abbott, S. M., Reid, K. J., Zee, P. C., y Allada, R. (2018). *Universal method for robust detection of circadian state from gene expression*. Proceedings of the National Academy of Sciences of the United States of America, 115(39):E9247–E9256. <https://doi.org/10.1073/pnas.1800314115>